



DIGITECH

Máster en Inteligencia Artificial y BIG DATA

Clasificación de las provincias españolas según su estructura económica

Un análisis basado en paro, renta media y distribución sectorial

Trabajo de Fin de Máster

Adrián Morales Palma

Curso 2025-2026

Indice


- 1. Resumen**
- 2. Introducción.**
- 3. Marco teórico.**
 - a. Clustering y K-Means.**
 - b. Normalización de datos.**
- 4. El proyecto.**
 - a. Datos utilizados.**
 - b. Resultados obtenidos.**
- 5. Despliegue del código**
- 6. Explicación del código.**
 - a. Carga y limpieza de datos.**
 - b. Normalización con StandardScaler.**
 - c. Selección de K mediante el método del codo.**
 - d. Corrección de nombres de provincias.**
 - e. Visualización con Folium.**
- 7. Conclusión.**
- 8. Bibliografía.**

Resumen

Este trabajo estudia cómo se distribuye la economía a lo largo de las provincias de España. La idea principal es descubrir si existen grupos de provincias que compartan niveles similares de paro, de renta y de conocer en qué sector destaca su población.

Para ello hemos utilizado técnicas de inteligencia artificial que agrupan automáticamente las provincias según sus características, sin necesidad de definir los grupos de antemano. El resultado es una clasificación en tres tipos de economía: industrial, agraria y de servicios.

Los resultados se presentan sobre un mapa interactivo de España, donde cada provincia aparece coloreada según el tipo de economía al que pertenece, facilitando una interpretación visual de la realidad económica del país.



Introducción

Una de las principales razones para empezar con este proyecto fue demostrar la diversidad económica que tiene España entre sus 52 provincias. Agrupamos las provincias en tres tipos de grupos, las que viven del campo, las que viven de la industria y las que viven del sector servicios. Con esto evaluamos cuántos grupos distintos existen realmente y qué provincias se parecen entre sí. También demostramos las diferencias visibles y económicas que hay entre la zona norte y sur, que históricamente siempre ha sido tema de debate por la marcada pobreza que sufre la parte sur del país.

Podríamos hacerlo a ojo, basándonos en lo que ya sabemos sobre cada territorio, pero ese enfoque es subjetivo y limitado. Este trabajo propone una forma diferente, que es dejar que los datos hablen por sí solos a través de la ayuda de la inteligencia artificial.

Para ello se recogen datos reales de tres variables económicas clave: la tasa de paro, la renta media y la distribución del empleo por sectores (agricultura, industria y servicios) de las 52 provincias españolas. Con esos datos se aplica una técnica de inteligencia artificial que agrupa automáticamente las provincias según sus similitudes, sin que nadie le diga de antemano cuántos grupos hay ni cómo deben ser.

El resultado es una clasificación de las provincias españolas en tres tipos de economía diferenciados, que se presenta sobre un mapa interactivo donde cada provincia aparece coloreada según el grupo al que pertenece. Una forma sencilla y visual de entender cómo se distribuye la economía a lo largo del territorio español.

Marco teórico

a. Clustering y K-Means

Cuando tenemos un conjunto de datos y queremos encontrar grupos naturales dentro de él sin saber de antemano cuántos hay ni cómo son, utilizamos el clustering, que se trata de un tipo de inteligencia artificial no supervisada en el que el algoritmo aprende solo a partir de los datos, sin que nadie le indique la respuesta correcta. Con esto logramos no condicionar los resultados por subjetividad.

Una de las técnicas de clustering que utilizamos en el proyecto es K-Means. Con esto conseguimos que el algoritmo intente agrupar los datos en varios grupos según lo parecidos que sean entre sí. Por ejemplo, si dos provincias tienen niveles similares de paro, renta o peso del sector servicios, el algoritmo tenderá a meterlas en el mismo grupo. La “K” representa el número de grupos que queremos crear. Elegir bien esa cantidad es importante, porque demasiados grupos pueden dividir demasiado los datos y muy pocos pueden mezclar provincias que realmente son diferentes.

b. Normalización de datos

Antes de aplicar K-Means es necesario preparar los datos correctamente. El problema es que las variables que usamos no están en la misma escala, es decir, la renta se mide en miles de euros, mientras que el paro se mide en porcentaje. Si no corregimos esto el algoritmo daría mucho más peso a la renta simplemente porque sus números son más grandes, y los resultados serían incorrectos.

Para evitarlo aplicamos la normalización, que transforma todas las variables para que estén en la misma escala y tengan el mismo peso a la hora de calcular los grupos.

El proyecto

a. Datos utilizados

Para realizar este análisis se han utilizado tres conjuntos de datos distintos, todos centrados en las provincias españolas.

- El primero es la **tasa de paro**, que muestra el porcentaje de personas que quieren trabajar pero no tienen empleo en cada provincia. Este dato sirve para ver qué zonas tienen más dificultades laborales y cuáles tienen una situación mejor.
- El segundo conjunto de datos es la **renta media por persona**. Básicamente, indica cuánto dinero gana de media la población de cada provincia y ayuda a hacerse una idea del nivel económico y de vida de cada territorio.
- Por último, también se ha utilizado la **distribución del empleo por sectores económicos**. Aquí se analiza qué porcentaje de personas trabaja en agricultura, industria y servicios. Esto es importante porque permite entender mejor en qué se basa la economía de cada provincia y qué tipo de actividad tiene más peso en ella.

b. Resultados obtenidos

El algoritmo terminó separando las provincias en tres grupos bastante distintos entre sí.


- El primero reúne provincias con una **economía más industrial**. En general, tienen menos paro, una **renta media más alta** y un **peso importante de la industria** dentro de su economía. La mayoría están situadas en el norte y noreste de España.
- El segundo grupo está formado por provincias con una **economía más agraria**. Suelen tener **rentas más bajas, más paro** y una **presencia mayor del sector agrícola**. Muchas de ellas se encuentran en el sur y en zonas del interior del país.
- El tercer grupo incluye provincias donde el **sector servicios tiene muchísimo peso**, especialmente por actividades relacionadas con el **turismo**. Aquí aparecen grandes ciudades y muchas zonas costeras, donde hoteles, comercio y servicios son una parte clave de la economía.


Despliegue del proyecto

El proyecto está desarrollado en un notebook de Python y está diseñado para ejecutarse en Google Colab, una plataforma gratuita de Google que permite ejecutar código Python directamente desde el navegador, sin necesidad de instalar nada en el ordenador. Por lo que únicamente necesitarás de conexión a internet y un navegador.

Para poner en marcha el proyecto basta con seguir estos pasos:

1. Acceder a [Google Colab](https://colab.research.google.com/) con una cuenta de Google.
2. Subir el archivo del notebook (.ipynb) desde el menú “**Archivo**”.





3. Subir los tres archivos de datos (paro.csv, renta.csv y sector.csv) al entorno de Colab desde el panel lateral izquierdo, en la pestaña “Archivos”.



4. Ejecutar las celdas en orden, de arriba a abajo. Esto se puede hacer una a una pulsando el botón de cada celda.

Bloque 1: Carga de datos

Objetivo: Traer los datos necesarios para analizar la economía de cada provincia

Ejecutar celda (Ctrl+Enter)
la celda no se ha ejecutado en esta sesión

hora de ejecución: hora desconocida

Librería para la manipulación de datos
import pandas as pd

Librerías de machine learning
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

Librerías para el mapa interactivo
import folium
import requests

paro
paro = pd.read_csv('paro.csv', sep=';', encoding='latin-1')

renta
renta = pd.read_csv('renta.csv', sep=';', encoding='latin-1')


sector
sector = pd.read_csv('sector.csv', sep=';', encoding='latin-1')
sector.head()

Provincias Sector económico Período Total

0	Total Nacional	Agricultura	2023T4	3,7
1	Total Nacional	Industria	2023T4	12,2
2	Total Nacional	Construcción	2023T4	6,2
3	Total Nacional	Servicios	2023T4	72,1
4	02 Albacete	Agricultura	2023T4	10,5

[1]
✓ 2 s

5. El mapa interactivo se va a generar automáticamente al final del notebook y se mostrará directamente en la pantalla.



Explicación del código

a. Carga y limpieza de datos

El primer paso del proyecto fue cargar los tres archivos CSV y dejar los datos ordenados para poder trabajar con ellos. Aunque los datos son oficiales, vienen bastante desorganizados y no se pueden usar directamente tal y como están.

Los archivos de paro y renta tenían muchas filas repetidas y una estructura algo liosa, así que hubo que reorganizarlos para que cada provincia tuviera sus datos de forma más clara.

Con el archivo de sectores económicos pasó algo parecido. Además, hubo que separar bien los porcentajes de agricultura, industria y servicios para poder usar cada uno por separado en el análisis. También decidí juntar industria y construcción en una sola variable porque ambos sectores suelen estar bastante relacionados y por separado complicaban más el análisis sin aportar demasiada diferencia. Al unirlos, era más fácil identificar provincias con un perfil económico más industrial y comparar mejor los resultados con las provincias más agrarias o más orientadas a servicios. Además, así el modelo quedaba más simple y fácil de interpretar.

Cuando ya estaban limpios los tres archivos, los uní en una sola tabla con toda la información importante de cada provincia: paro, renta y peso de cada sector económico.

Antes de seguir, también tuve que eliminar algunos valores vacíos o incorrectos, porque el algoritmo K-Means no funciona bien si faltan datos.

b. Normalización con StandardScaler

Cuando ya tenía los datos limpios y ordenados, el siguiente paso fue normalizarlos. Básicamente consiste

en hacer que todas las variables estén en una escala parecida antes de usar el algoritmo.

Esto hay que hacerlo porque los datos que estamos usando tienen números muy diferentes entre sí. Por ejemplo, la renta puede estar en 15.000 o más, mientras que el paro o los sectores económicos son porcentajes bastante más pequeños. Si se usan así directamente, el algoritmo pensaría que la renta es muchísimo más importante solo porque sus números son mayores, y acabaría creando grupos raros o poco fiables.

Para evitar eso utilicé **StandardScaler**, una herramienta de **scikit-learn** que se encarga de ajustar automáticamente los datos para que todas las variables tengan un peso parecido dentro del análisis.

En el código seleccioné las columnas que quería usar (**Paro**, **Renta**, **Agricultura**, **Industria_total** y **Servicios**) y las normalicé. El resultado se guardó en una nueva variable llamada **X_normalizado**, que es la que luego usa K-Means para crear los clusters.

Los datos originales no cambian ni se pierden. Simplemente se crea una copia adaptada para que el algoritmo pueda trabajar mejor con ella.

c. Selección de K mediante el método del codo

Antes de usar K-Means tuve que decidir cuántos grupos quería crear. Ese número es la famosa “K” del nombre del algoritmo. El problema es que el algoritmo no sabe solo cuántos grupos existen, así que hay que decírselo antes.

Para elegirlo utilicé una técnica llamada **método del codo**. La idea es bastante simple: probar el algoritmo varias veces usando distintos números de grupos y ver cuál funciona mejor. En mi caso probé desde 1 hasta 10 grupos distintos.

Cada vez que el algoritmo crea los grupos, calcula una cosa llamada **inercia**. Básicamente sirve para medir cómo de bien agrupados están los datos. Cuanto más baja sea la inercia, mejor. El problema es que si sigues añadiendo grupos, la inercia siempre baja, así que hay que encontrar el punto donde deja de mejorar tanto.

Por eso después se hace una gráfica. Al principio la línea baja muchísimo, pero llega un momento en el que empieza a bajar mucho más lento. Ese punto donde la curva parece hacer un “codo” suele indicar el número ideal de grupos.

En el proyecto, el codo aparecía bastante claro en **K=3**, así que decidí usar tres clusters porque era el punto donde el algoritmo seguía funcionando bien sin complicar demasiado el análisis.

Una vez elegido ese número, ejecuté K-Means de forma definitiva con 3 grupos y añadí una nueva columna llamada Cluster, que indica a qué grupo pertenece cada provincia.

d. Corrección de nombres de provincias

Cuando ya tenía los clusters creados, el siguiente paso fue mostrarlos en un mapa para que los resultados se entendieran mejor visualmente. Para hacer eso utilicé un archivo **GeoJSON** que encontré gracias a un usuario de **GitHub**, básicamente contiene las formas y fronteras de todas las provincias de España y permite dibujarlas en un mapa interactivo.

El principal problema aquí fue que muchos nombres de provincias no coincidían exactamente entre el GeoJSON y mis datos. Por ejemplo, en mis datos aparecía “**Coruña, A**” y en el mapa salía como “**A Coruña**”. Con otras provincias pasaba algo parecido. Esto era importante porque si los nombres no coinciden exactamente el programa no sabe qué datos pertenecen a cada provincia y entonces la pinta en gris y sin información.

Para solucionarlo hice una copia del dataframe llamada **df_mapa** y corregí manualmente los nombres que daban problemas usando un diccionario de reemplazos. Básicamente, fui igualando los nombres de mis datos a los nombres que usaba el GeoJSON.

Después el código recorre automáticamente todas las provincias del mapa y busca sus datos correspondientes en el dataframe. Cuando encuentra coincidencia, le añade toda la información del análisis: **el cluster** al que pertenece, **el tipo de economía**, **el paro**, **la renta** y **los porcentajes de agricultura, industria y servicios**.

Gracias a eso, cuando pasas el ratón por encima de una provincia en el mapa, aparece toda esa información en una pequeña ventana emergente.

e. Visualización con Folium

Para crear el mapa interactivo utilicé una librería llamada **Folium**, que permite hacer mapas directamente desde **Python** de una forma bastante sencilla. Básicamente, Folium genera un archivo **HTML** con el mapa ya montado, que luego se puede abrir en un navegador o mostrar dentro de Google Colab.

Primero creé un mapa base centrado en España y ajusté el zoom para que se vieran bien tanto la península como las islas. También desactivé todas las opciones de mover el mapa, hacer zoom o clicar, porque la idea no era hacer un mapa “navegable”, sino una visualización fija y limpia para el TFM. Como fondo usé **cartodbpositron**, que tiene un estilo muy simple y queda bastante bien visualmente porque no distrae demasiado.

Después añadí encima las provincias usando el GeoJSON que ya tenía preparado con todos los datos del clustering. Cada provincia se colorea según el grupo al que pertenece: **azul para las economías más industriales, naranja para las más agrarias y verde para las más orientadas a servicios**. Si alguna provincia no tiene datos o no encuentra coincidencia, aparece en gris.

También añadí un **tooltip**, que es la pequeña ventana que aparece cuando pasas el ratón por encima de una provincia. Ahí se muestra toda la información importante: **nombre de la provincia, tipo de economía, paro, renta y porcentajes de agricultura, industria y servicios**.

Por último, guardé el mapa como un archivo HTML y lo incrusté dentro del notebook usando un **iframe**. Tuve que hacerlo así porque Colab no muestra bien los mapas de Folium directamente, pero sí permite enseñar páginas HTML dentro del propio notebook.

Conclusión

Este trabajo ha demostrado que se pueden agrupar las provincias españolas en distintos grupos económicos de manera bastante objetiva, utilizando únicamente datos públicos de paro, renta y cómo se distribuye el empleo por sectores.

El algoritmo K-Means ha sacado tres tipos de provincias bastante claros. Por un lado, hay un grupo con economías más industriales, con rentas más altas y menos paro, que se concentra sobre todo en el norte y noreste del país. Por otro, aparece un grupo de provincias más agrícolas, con rentas más bajas y mayor desempleo, que se encuentra principalmente en el sur y en zonas del interior. Y por último, hay un tercer grupo más centrado en los servicios, donde destacan sobre todo las grandes ciudades y las zonas costeras con mucho turismo.

Lo más interesante es que los resultados no parecen aleatorios, los grupos tienen sentido tanto a nivel geográfico como económico. El algoritmo realmente ha detectado patrones reales y no simples agrupaciones sin significado. Se demuestra que España tiene una estructura económica bastante marcada por territorios, y lo dejamos bastante claro de forma visual.

Cabe recalcar que el análisis se basa en un número limitado de variables y datos de un momento concreto en el tiempo. Agregar más indicadores económicos seguramente enriquecería el análisis. Esto nos confirma que con pocos datos públicos y haciendo un buen uso de la inteligencia artificial se puede hacer un análisis preciso y certero sobre la realidad económica de un país.

Bibliografía

1. INE (2023). Tasas de actividad, paro y empleo por provincia y sexo.
<https://www.ine.es/jaxiT3/Tabla.htm?t=3996>
2. INE (2023). Indicadores de renta media y mediana.
<https://www.ine.es/jaxiT3/Tabla.htm?t=53689>
3. INE (2023). Distribución porcentual de los activos por sector económico y provincia.
<https://www.ine.es/jaxiT3/Tabla.htm?t=3994>
4. GITHUB (2022). GeoJSON con las provincias españolas para el mapa interactivo.
https://github.com/codeforgermany/click_that_hood/blob/main/public/data/spain-provinces.geojson